

Documento de trabajo — Framework para Evaluar Seguridad de Modelos en Español

1. Objetivo del paper

Queremos construir un framework para que organizaciones puedan evaluar qué tan seguro es un modelo de lenguaje cuando opera en español.

El foco no es crear “otro benchmark”, sino una matriz de madurez que permita responder:

¿Qué evidencia necesita una organización para confiar en un modelo usado en español?

El framework extiende la lógica OWMI, pero la adapta a evaluación lingüística y organizacional en español.

2. Tesis central

Un modelo no debería ser considerado seguro de forma general si su seguridad no fue validada empíricamente en el idioma y contexto donde será usado.

En nuestro caso:

Safe in English $\neq$ Safe in Spanish.

La seguridad debe evaluarse por idioma, variante regional, dominio de uso y condiciones reales de deployment.

3. Contribución esperada

El paper debería aportar tres cosas:

1. Una adaptación de la matriz OWMI para seguridad en español.
 2. Una taxonomía de riesgos específicos para modelos usados en español.
 3. Un protocolo de evaluación y scoring para que organizaciones puedan ratear modelos.
-

4. Preguntas principales que el paper debe responder

Pregunta 1 — ¿Por qué evaluar seguridad en español por separado?

Qué tenemos que responder

- ¿Qué riesgos aparecen cuando se asume que seguridad en inglés transfiere a español?
- ¿Los modelos fallan distinto en español, dialectos, spanglish o traducciones?
- ¿Por qué esto importa para organizaciones en América Latina y el Sur Global?

Datos necesarios

- Papers sobre multilingual safety.
 - Ejemplos de jailbreaks que funcionan en español.
 - Evidencia de diferencias de refusal/safety entre idiomas.
 - Comparación simple entre inglés y español en algunos modelos.
-

Pregunta 2 — ¿Qué significa que un modelo sea “seguro en español”?

Qué tenemos que responder

Un modelo seguro en español debería:

- rechazar instrucciones dañinas en español;
- no rechazar consultas benignas;
- resistir jailbreaks y traducciones evasivas;
- no filtrar información sensible;
- no alucinar en dominios críticos locales;
- mantener seguridad tras fine-tuning o adaptación;
- ser trazable y verificable.

Datos necesarios

- Definición operativa de “seguridad en español”.
 - Lista de riesgos incluidos y excluidos.
 - Métricas asociadas a cada riesgo.
 - Ejemplos de casos seguros, inseguros y ambiguos.
-

5. Matriz central del framework

El framework se organiza en tres verticales, siguiendo la estructura OWMI.

Vertical 1 — Spanish Upstream Data Curation

Pregunta central

¿El modelo fue entrenado y curado para ser seguro en español, o simplemente aprendió español de forma no auditada?

Qué hay que validar

- Cobertura de español en pretraining.
- Cobertura de variantes regionales.
- Presencia de datos de safety en español.
- Filtrado de conocimiento peligroso en español.
- Toxicidad, sesgos y estereotipos locales.
- Calidad factual sobre dominios hispanohablantes.

Preguntas a responder

1. ¿Qué porcentaje del corpus está en español?
2. ¿Qué variantes del español están representadas?
3. ¿La curación de datos se hizo en español o solo en inglés?
4. ¿Se usaron filtros semánticos o solo keyword filtering?
5. ¿Se removió conocimiento peligroso en dominios como ciber, bio, fraude, violencia o autolesión?
6. ¿El modelo tiene sesgos o toxicidad específicos contra grupos hispanohablantes?
7. ¿El modelo alucina más en temas locales de salud, derecho, finanzas, educación o gobierno?

Datos que necesitamos

- Distribución lingüística del corpus.
- Fuentes de datos en español.
- Descripción del pipeline de curación.
- Categorías de contenido removido.
- Benchmarks o probe tests sobre conocimiento peligroso residual.
- Evaluaciones de toxicidad y sesgo en español.
- Evaluaciones de factualidad local.

Métricas posibles

- Spanish corpus coverage.
- Regional coverage score.
- Dangerous knowledge probe score.
- Toxicity rate.

- Bias score.
- Factuality score.
- False citation rate.

Niveles de madurez

Nivel	Criterio
L1 — Básico	El modelo declara soporte para español, pero no publica evidencia de curación específica.
L2 — Documentado	Publica información sobre corpus, filtros y benchmarks en español.
L3 — Empírico/ Auditado	Demuestra con pruebas externas que redujo conocimiento peligroso, toxicidad y fallos factuales en español.

Vertical 2 — Spanish Weight Provenance & Robustness

Pregunta central

¿Podemos verificar que el modelo usado en español es el modelo evaluado, y que mantiene seguridad tras adaptaciones locales?

Qué hay que validar

- Identidad exacta del modelo.
- Hashes y versionado.
- Watermarking de pesos.
- Fine-tuning en español.
- LoRA, merges, quantization y pruning.
- Abliteration o remoción de alignment.
- Supervivencia de provenance después de modificaciones.

Preguntas a responder

1. ¿La organización puede verificar qué versión exacta está usando?
2. ¿El modelo tiene solo metadata o tiene watermarking verificable?
3. ¿El watermark sobrevive fine-tuning en español?
4. ¿La seguridad cae después de LoRA, merge, quantization o pruning?
5. ¿Un atacante puede remover restricciones de seguridad con bajo costo?
6. ¿Se puede atribuir un modelo derivado al modelo original?
7. ¿El modelo evaluado es realmente el mismo que se despliega?

Datos que necesitamos

- Hashes.
- Model card.

- Version card.
- Método de watermarking.
- Prueba de verificación del watermark.
- Resultados de seguridad antes y después de fine-tuning.
- Resultados antes y después de LoRA/merge/quantization.
- Evidencia sobre degradación de refusal o aumento de jailbreak success.

Métricas posibles

- Watermark verification success.
- Watermark survival rate.
- Safety degradation delta.
- Attack Success Rate delta.
- Refusal rate delta.
- Harmfulness score delta.
- Provenance confidence score.

Niveles de madurez

Nivel	Criterio
L1 — Básico	Publica hash, metadata o versión, pero sin trazabilidad robusta.
L2 — Documentado	Usa watermarking o mecanismo de provenance y documenta el método.
L3 — Empírico/ Auditado	Un tercero verifica que provenance y seguridad sobreviven adaptaciones en español.

Vertical 3 — Spanish Tiered Release & Testing

Pregunta central

¿El modelo fue testeado adversarialmente en español antes de ser liberado o usado por organizaciones?

Qué hay que validar

- Jailbreaks en español.
- Prompt injection en español.
- RAG poisoning con documentos en español.
- Translation loopholes.
- Code-switching y spanglish.
- Dialectos y jerga local.
- Hallucination en dominios sensibles.
- Privacy leakage.
- Tool-use abuse.
- Red-teaming con hablantes nativos.

Preguntas a responder

1. ¿Se evaluaron ataques en español o solo benchmarks en inglés?
2. ¿Los prompts fueron traducidos o escritos por hablantes nativos?
3. ¿Se probaron variantes regionales?
4. ¿Se probaron ataques multi-turn?
5. ¿Se midió over-refusal además de under-refusal?
6. ¿Se evaluó prompt injection en documentos en español?
7. ¿Se evaluó RAG con fuentes maliciosas o no confiables?
8. ¿Se evaluó uso de herramientas?
9. ¿Hubo red-team externo o solo evaluación interna?
10. ¿Los resultados se publicaron por categoría de riesgo?

Datos que necesitamos

- Set de prompts benignos en español.
- Set de prompts adversariales en español.
- Variantes regionales de prompts.
- Casos de spanglish/code-switching.
- Casos de traducción evasiva.
- Casos multi-turn.
- Documentos con prompt injection.
- Logs de agentes/herramientas.
- Evaluación humana o LLM-as-a-judge calibrado.
- Resultados por modelo, riesgo y variante lingüística.

Métricas posibles

- Attack Success Rate.
- Refusal rate.
- Over-refusal rate.
- Harmfulness score.
- Helpfulness score.
- Prompt injection success rate.
- Data exfiltration rate.
- Tool violation rate.
- Task success under attack.
- Human agreement score.

Niveles de madurez

Nivel	Criterio
L1 — Básico	Pruebas internas limitadas o ejemplos manuales.
L2 — Documentado	Publica benchmarks y resultados separados para español.
L3 — Empírico/ Auditado	Red-team externo con hablantes nativos y reporte adversarial antes del release/deployment.

6. Taxonomía de riesgos

El paper debe incluir una taxonomía mínima de riesgos. Estos riesgos no son verticales; son tests que alimentan la matriz.

Riesgo	Vertical principal
Jailbreaks	Tiered Release & Testing
Hallucination	Upstream Data Curation + Testing
Prompt injection	Tiered Release & Testing
RAG poisoning	Tiered Release & Testing
Data leakage	Tiered Release & Testing
Toxicidad/sesgo	Upstream Data Curation + Testing
Unsafe capabilities	Upstream Data Curation + Testing
Multilingual evasion	Tiered Release & Testing
Translation loopholes	Tiered Release & Testing
Tool-use abuse	Tiered Release & Testing
Abliteration	Weight Provenance + Testing
Fine-tuning degradation	Weight Provenance
Watermark evasion	Weight Provenance
Evaluation gaming	Tiered Release & Testing

7. Fases para construir el paper

Fase 1 — Definir el problema

Preguntas a resolver

- ¿Cuál es el gap del OWMI original?
- ¿Por qué el idioma debe ser una dimensión de seguridad?
- ¿Por qué español es un caso relevante?
- ¿Qué organizaciones se beneficiarían del framework?

Datos necesarios

- Argumento geopolítico: Sur Global y soberanía tecnológica.
 - Argumento técnico: safety no transfiere perfectamente entre idiomas.
 - Argumento organizacional: instituciones necesitan criterios de adopción.
-

Fase 2 — Revisar literatura

Preguntas a resolver

- ¿Qué papers validan evaluación multilingüe de safety?
- ¿Qué benchmarks existen para jailbreaks?
- ¿Qué benchmarks existen para refusal?
- ¿Qué benchmarks existen para prompt injection/agentes?
- ¿Qué trabajos existen sobre watermarking/provenance?
- ¿Qué trabajos existen sobre model editing, ablation o safety degradation?

Datos necesarios

- Tabla de papers.
 - Qué evalúa cada paper.
 - Qué métrica usa.
 - Si incluye español o no.
 - Limitaciones para nuestro framework.
-

Fase 3 — Diseñar la matriz

Preguntas a resolver

- ¿Cómo se adaptan las tres verticales OWMI al español?
- ¿Qué niveles de madurez usamos?
- ¿Qué evidencia exige cada nivel?
- ¿Qué criterios son obligatorios y cuáles opcionales?

Datos necesarios

- Matriz final.
 - Definición de cada vertical.
 - Criterios L1/L2/L3.
 - Justificación de por qué cada criterio importa.
-

Fase 4 — Diseñar protocolo de evaluación

Preguntas a resolver

- ¿Qué modelos se evaluarán?
- ¿Qué prompts se usarán?
- ¿Qué variantes del español se incluirán?
- ¿Cómo se evaluarán outputs?
- ¿Habrá evaluación humana, LLM judge o ambas?
- ¿Cómo se evitará que el modelo gane rechazando todo?

Datos necesarios

- Dataset de prompts.
 - Categorías de riesgo.
 - Guía de anotación.
 - Métricas.
 - Protocolo de scoring.
 - Ejemplos de outputs clasificados.
-

Fase 5 — Ejecutar caso de estudio

Preguntas a resolver

- ¿Qué modelos vamos a comparar?
- ¿Qué diferencias aparecen entre modelos?
- ¿Qué diferencias aparecen entre inglés y español?
- ¿Qué ataques funcionan mejor en español?
- ¿Qué verticales muestran más debilidad?

Datos necesarios

- Resultados por modelo.
 - Resultados por vertical.
 - Resultados por riesgo.
 - Resultados por variante lingüística.
 - Casos cualitativos representativos.
 - Tabla de rating final.
-

Fase 6 — Definir uso organizacional

Preguntas a resolver

- ¿Cómo debería usar este framework una organización?
- ¿Qué nivel mínimo se requiere para cada tipo de deployment?

- ¿Qué riesgos requieren controles adicionales?
- ¿Qué evidencia debería pedir una organización a un proveedor?

Datos necesarios

- Recomendaciones por caso de uso.
- Ejemplo de scorecard organizacional.
- Umbrales de adopción.
- Limitaciones del framework.

8. Scorecard tentativa

Vertical	Peso sugerido	Qué mide
Spanish Upstream Data Curation	35%	Si el modelo fue entrenado/curado con seguridad real en español.
Spanish Weight Provenance & Robustness	25%	Si el modelo y sus derivados son verificables y mantienen seguridad tras adaptación.
Spanish Tiered Release & Testing	40%	Si el modelo fue testeado adversarialmente en español antes de uso organizacional.

La ponderación puede cambiar según el caso de uso.

Para modelos usados con RAG o agentes, Tiered Release & Testing debería pesar más.

Para modelos fine-tuned localmente, Weight Provenance & Robustness debería pesar más.

Para modelos usados en salud, educación, finanzas o gobierno, Upstream Data Curation debería pesar más.

9. Datos mínimos para que el paper sea defendible

Necesitamos producir al menos:

1. Matriz OOWMI adaptada a español.
2. Taxonomía de riesgos.
3. Tabla de literatura relacionada.
4. Dataset pequeño de prompts en español.
5. Prompts benignos y adversariales.
6. Variantes regionales o code-switching.
7. Métricas claras.
8. Evaluación de 2 a 4 modelos.

9. Resultados por vertical.
 10. Scorecard final.
 11. Discusión de limitaciones.
 12. Recomendaciones para organizaciones.
-

10. Estructura sugerida del paper

1. Introduction

Presentar el problema: los modelos son evaluados principalmente en inglés, pero muchas organizaciones los usan en español.

2. Background

Explicar OWMI, open-weight governance, multilingual safety y necesidad de evaluación empírica.

3. Threat Model

Definir riesgos considerados: jailbreaks, hallucinations, prompt injection, privacy leakage, toxicidad, unsafe capabilities y degradation post-fine-tuning.

4. Spanish Safety Maturity Framework

Presentar las tres verticales adaptadas:

1. Spanish Upstream Data Curation.
2. Spanish Weight Provenance & Robustness.
3. Spanish Tiered Release & Testing.

5. Evaluation Protocol

Explicar prompts, variantes lingüísticas, métricas, jueces, scoring y niveles de madurez.

6. Case Study

Aplicar el framework a varios modelos y mostrar resultados.

7. Organizational Use

Explicar cómo una organización debería interpretar el rating y tomar decisiones de adopción.

8. Limitations

Reconocer límites: tamaño del benchmark, cobertura regional, subjetividad de jueces, falta de acceso a training data, dificultad de auditar watermarks.

9. Conclusion

Defender la idea central: la seguridad de modelos debe validarse en el idioma real de deployment.

11. Decisiones pendientes del equipo

Decisión 1 — Nombre del framework

Opciones:

- Spanish Model Safety Maturity Framework.
- Spanish OWMi Extension.
- Spanish-Language Model Safety Index.
- S-OWMI: Spanish Open-Weight Maturity Index.

Decisión 2 — Scope inicial

Elegir si el paper se enfoca en:

- solo open-weight models;
- open-weight + API models;
- modelos organizacionales con RAG/agentes;
- modelos fine-tuned en español.

Recomendación: empezar con open-weight models y mencionar extensión futura a APIs.

Decisión 3 — Modelos a evaluar

Elegir 2 a 4 modelos.

Criterios:

- disponibilidad;
- uso real;
- soporte español;
- tamaño ejecutable;
- relevancia para organizaciones.

Decisión 4 — Variantes de español

Mínimo:

- español neutro;
- español LATAM;
- español rioplatense;
- spanglish/code-switching.

Ideal:

- español mexicano;
- español chileno;
- español colombiano;
- español España.

Decisión 5 — Evaluación humana vs automática

Opción mínima:

- LLM-as-a-judge + revisión humana de muestra.

Opción fuerte:

- anotadores nativos + LLM judge calibrado.

Decisión 6 — Nivel de ambición

Opción hackathon:

- framework + mini case study.

Opción paper más sólido:

- framework + dataset + evaluación comparativa + recomendaciones organizacionales.

12. Frase guía

El paper debe sostener esta idea:

La seguridad de un modelo no debe evaluarse solo a nivel global; debe validarse empíricamente en el idioma, variante regional y contexto organizacional donde será desplegado.

Para nuestro caso:

Un modelo seguro para organizaciones hispanohablantes necesita evidencia específica de curación, trazabilidad y testing adversarial en español.